
Manuscript ID 4001 - Editor Decision

1 mensaje

Editorial Team <journal@lidi.info.unlp.edu.ar>

5 de enero de 2026 a las 12:24

Para: Berly Joel Diaz Castro <bldiazca@unsa.edu.pe>

Berly Joel Diaz Castro, Roxana:

We have reached a decision regarding your submission to Journal of Computer Science and Technology, "Speech-To-Text Translation Using End-To-End Transformer Models".

Our decision is to: Decline Submission

Reviewer 1:

Recommendation: See Comments

General comments:

El artículo compara dos enfoques en la traducción automática (español a inglés) de voz a texto, uno con dos etapas (transcripción + traducción), ASR+MT en la revisión, y otro extremo a extremo (end-to-end). La comparación se realiza entre el modelo Whisper-Large-V3 (end-to-end) y Whisper-Large-V3 + mBART (ASR+MT). En el segundo caso Whisper-Large-V3 se usa solo como ASR, porque toma el audio en español y lo convierte en texto en español para ser traducido al inglés después con mBART. Sobre los modelos se realizó fine tuning. Los resultados indican que el enfoque end-to-end es mejor para la métrica BLEU.

Tal como se menciona en la introducción, el problema de ASR+MT es la propagación de errores entre las etapas y el enfoque para mitigarlo es precisamente utilizar modelos end-to-end. Whisper-Large-V3 es un modelo end-to-end creado por OpenAI bajo esa idea.

1) Is the question addressed by the authors relevant and well defined?

Considero que la hipótesis del trabajo está clara y bien definida, se intenta demostrar que el enfoque end-to-end es mejor. Por otro lado, considero que el trabajo tiene valor didáctico y puede servir como estudio de caso, pero que el aporte científico es débil, no por la pregunta en sí, sino porque no se propone un método (a pesar de que al modelo usado en el enfoque end-to-end se lo llama "proposed method") ni una idea novedosa, sino que se utiliza desarrollos existentes para realizar experimentos que (salvo por la elección de los datos) ya habían sido realizados por otros autores y cuyos resultados se exponen en este mismo artículo. El resultado principal, que muestra que Whisper usado en modo end-to-end supera a una arquitectura cascada construida con Whisper + mBART, es coherente con el diseño original de Whisper. Dado que Whisper fue entrenado específicamente para tareas de traducción directa de voz a texto, no sorprende que el rendimiento se degrade al utilizarlo para una sola tarea y combinarlo con otro modelo. La comparación confirma una expectativa de diseño más que aportar un hallazgo novedoso o una contribución metodológica nueva. Para reforzar el valor del trabajo, se recomienda incluir experimentos con ASR y MT estados del arte independientes, o un análisis más profundo de casos donde la cascada sí podría superar al enfoque end-to-end.

2) Is the submission original? Does it significantly build on (the author's) previous work?

Sí, el artículo es original. No se mencionan trabajos previos de los autores.

3) Are the methods adequate and well described? Is possible to replicate the work considering the details provided?

Considero que el nivel de detalles en la descripción de los métodos es correcta y suficiente.

4) Are the discussion and conclusions well balanced and adequately supported by the data/experimental work?

- En la introducción solo se exponen las ventajas de uno de los enfoques (end-to-end). Si el otro enfoque no tiene ninguna, el análisis pierde valor. Sugiero que se expongan las ventajas y desventajas de cada enfoque de forma que tenga sentido la comparación. En otras palabras, explicar por qué alguien podría utilizar el método cascada. Esta ventajas/desventajas deberían ser después discutidas en base a los resultados de los experimentos.

- La comparación entre las tablas 7 y 8 no validan la hipótesis para otros modelos que logran mejores resultados, de hecho hay un caso con los mismos modelos que en este trabajo. Se debería discutir este hecho en el artículo. ¿Por qué razón en otros artículos hay resultados tan distintos?

5) Is the writing acceptable? If not, how could it be improved?

Sí, la escritura es aceptable. Hay algunas correcciones menores que se sugieren al final.

6) Are the title, abstract and keywords appropriate in relation to the article contents?

En el artículo la comparación entre los enfoques es central. Considero que se debería interpretar al leer el título.

Major revisions (issues that the author must answer before a decision on the article can be taken):

Minor revisions (issues that the author can be trusted to correct, such as missing labels, typos, etc):

- Considero que el término "proposed method" no es correcto, porque no se propone un método novedoso.

- Sugiero reemplazar "Transformers" por "Transformer" en "cascade systems based on Transformer [16]" y eliminar la referencia 16, ya que los transformers son arquitecturas sumamente conocidas en el área.

- En "sequence-to-sequence or end-to-end model", "sequence-to-sequence" se refiere a una cosa y "end-to-end" a otra, pero parecen sinónimos. Se debería expresar de otra manera.

- En las figuras 1 y 2 se muestran los métodos a comparar. En la figura 2 hay un esquema del modelo, pero en la figura 1 no hay esquemas de los modelos. Esto dificulta la comprensión. Usar el mismo criterio en las dos figuras.

- En la sección 5 hay una frase que dice "In the experiments, the data set mentioned in Section 3.2 was used...", pero el dataset se presenta en 4.1. La sección 3.2 no existe. Por favor revisar todas las referencias. Podría haber más casos si no se usó un método automático para referenciar.

- Se comenta cuántas horas de audio tiene CoVoST2 sumando todos los idiomas, pero no cuántas horas hay en español ni cuántas se usaron (train/test), que es un dato más relevante para el trabajo.

- En las tablas, donde hay valores numéricos, alinear a la derecha y usar una cantidad fija de decimales. Al texto alinearlos a la izquierda.

- En la tabla 7, "Proposed Method + mBART-Large-50" sería "Whisper-Large-V3 + mBART-Large-50"?

Optional revisions (recommendations to improve the article but which the author can ignore):

Reviewer's knowledge in the subject:

7

Reviewer 2:

Recommendation: Decline Submission

General comments:

While the manuscript addresses a relevant topic in the field of speech-to-text translation and employs widely used end-to-end transformer models, the overall contribution of the work is limited. The proposed approach largely relies on established architectures and techniques, and the manuscript does not clearly articulate a novel methodological contribution or a significant advancement over existing state-of-the-art approaches.

Moreover, the experimental section lacks sufficient detail to ensure reproducibility. Important information regarding data preprocessing, model configuration, training procedures, and computational environment is either missing or only superficially described. This makes it difficult to properly assess the validity and robustness of the reported results.

The experimental analysis is mostly descriptive and does not include thorough comparisons with strong baselines, ablation studies, or statistical validation. As a result, the conclusions, while reasonable, are not fully supported by a deep or comprehensive evaluation.

Finally, the manuscript would benefit from substantial improvements in writing quality and organization. Several grammatical issues, unclear formulations, and repetitive explanations reduce clarity and weaken the overall presentation.

For these reasons, I would recommend declining the manuscript in its current form. A substantially revised version, with clearer articulation of novelty, more rigorous experimental methodology, stronger comparative analysis, and improved writing, would be necessary for reconsideration.

Major revisions (issues that the author must answer before a decision on the article can be taken):

Minor revisions (issues that the author can be trusted to correct, such as missing labels, typos, etc):

Optional revisions (recommendations to improve the article but which the author can ignore):

Reviewer's knowledge in the subject:

6